# 第四节 人工智能辅助成药性评价

传统的成药性评价方法是基于体外或体内的实验，通常需要耗费较大的人力、物力、财力，且难以做到高通量，不利于在早期阶段筛选掉成药性差的先导化合物；而随着机器学习和人工智能（AI）的兴起，利用计算模型辅助成药性评价成为研究的热点话题，围绕上述诸多指标涌现出了一批 AI 成药性评价模型。这极大减轻了研究的成本，加速了新药的研发历程。下面将根据不同方面分别介绍 AI 辅助成药性评价的研究及案例。

## 一、人工智能辅助药物代谢预测

现有药物代谢物预测模型主要涉及药物代谢位点预测和药物代谢物预测。药物代谢位点（SoM）预测模型旨在预测发生代谢转化分子中的原子，可用于深入了解药物代谢稳定性，帮助药物化学家进行结构改造；药物代谢物预测模型则旨在直接预测药物可能的代谢产物，进而有助于更好地理解药物可能的毒性及不良反应。一些代表性的代谢预测模型如表 2－3 所示。

表 2－3 现有报道的代谢预测模型

| 预测种类 | 模型名称 | 模型架构 |
|---|---|---|
| 代谢位点 | SMARTCyp | 人工规则 |
| | SMARTCyp3.0 | 人工规则 |
| | FAME | 随机森林 |
| | FAME2 | 极端随机树 |
| | FAME3 | 极端随机树 |
| | XenoSite | 深度神经网络 |
| | CypReact | 人工规则与机器学习结合 |
| | GNN－SOM | 图神经网络 |
| 代谢产物 | SyGMa | 人工规则 |
| | GLORY | 人工规则与机器学习结合 |
| | GLORYx | 人工规则与机器学习结合 |
| | CyProduct | 人工规则与机器学习结合 |
| | BioTransformer | 人工规则 |
| | Metabolic Forest | 人工规则 |
| | Meta-Trans | Transformer |

早期的研究工作主要集中于药物 SoM 的预测，如 SMARTCyp、FAME、XenoSite、CypReact、GNN－SOM 等，此类工具通常采用分子指纹或物理化学描述符来描述分子，使用传统机器学习模型或深度神经网络预测给定分子原子级别或键级别的代谢位点。然而，此类工具大多数局限于 CYP450 酶系介导的代谢反应预测，且往往局限于代谢反应发生的原子，潜在毒性代谢物结构的无法可视化是本类方法的固有缺陷。

为了更好展示可能的代谢产物结构，一些研究提出了基于人工定义规则的代谢物预测模型，如 SyGMa、GLORY 及 GLORYx、BioTransformer、Metabolic Forest 等。专家通过统计代谢数据库中反应的频率，人工制定任意目标的 SMILES 表示（SMARTS）规则预测给定分子的可能代谢产物。此类方法通常

扫描全能王
3亿人都在用的扫描App

要大量的人类操作成本，同时反应规则的增加可能导致更多结构的预测失误，降低预测的精度。此外，人工定义的规则显然无法涵盖所有的反应类型，进而导致规则外可能代谢产物的预测失败。

近年来，Kavarki 等将生物体内的代谢过程视为化学反应的一种，把反应产物预测问题被视为机器翻译问题的一种，应用自然语言处理中常见的序列到序列模型，将反应分子的 SMILES 作为模型输入，可能代谢产物的 SMILES 为模型输出，提出了 Meta-Trans 模型。该模型首先使用基于 Lowe 的美国专利及商标局（USPTO）化学反应数据集对模型进行预训练，利用迁移学习，将收集到的代谢反应数据用于预训练模型的微调中。同时该模型通过对 SMILES 随机化进行数据增强，采用波束搜索（beam search）以加强输出结果的丰富性，最终将采取不同处理方式 SMILES 训练得到的 6 个模型组合成集成模型（ensemble model）。该集成模型与现有模型（GLORYx、BioTransformer、SyGMa）相比较均取得了相似的预测性能。

## 二、血浆暴露

药物的血浆暴露度通常指的是药物在血浆中的浓度随时间变化的特征，它是衡量药物在体内药代动力学特性的一个重要指标。

药物发现早期阶段的计算机辅助药动学（PK）预测受到越来越多的关注，以避免先导化合物优化过程中不必要的测试，最大限度地减少资源的消耗。目前已有许多机器学习参与预测 PK 参数的研究进展。在药物血浆暴露度建模过程中，常会遇到数据不确定性高，样本量不足等问题，郑明月等提出了将“主动学习（active learning）”策略应用于药物口服血浆暴露预测的方法。该方法具有从噪声数据集中采样信息数据的能力，并且仅通过少量样本训练就能产生准确度较高的预测结果。拜耳公司将基于生理学的药代动力学模型与用于分子特性预测的深度学习模型结合成一个混合模型，以直接根据化学结构预测小分子的 PK 参数。与纯深度学习模型不同，混合模型可以预测未经训练的端点。通过评估全浓度时间（$c$-$t$）曲线和相应 PK 参数的预测（无须重新训练），混合模型的这种外推能力得到了证明。目前也有许多公开的 PK 参数预测工具，如瑞士生物信息学研究所分子建模团队开发的 SwissADME，可预测化合物的 ADME 参数、药代动力学特性、成药性和药物化学友好性。此外，我国研究人员自主研发的 admetSAR，覆盖了多个药代动力学终点，并涵盖化合物 ADMET（吸收、分布、代谢、排泄和毒性）性质优化的模块，已被国内外广泛使用。

## 三、血-脑屏障渗透性

随着实验数据的不断增加，基于机器学习和深度学习的方法在化合物血-脑屏障渗透性预测方面的应用也逐渐增多。传统机器学习方法首先对化合物分子进行血-脑屏障渗透相关特征提取，包括分子量、脂溶性、极性表面积、氢键供体数、氢键受体数和芳环数量等，将这些特征表示为分子描述符，或使用分子指纹作为模型的输入。机器学习算法如支持向量机、K 最近分类算法、随机森林和梯度提升机（GBM）等被用来训练模型，从而学习化合物特征与其血-脑屏障透过性之间的关系。这一过程需要专家知识来选择和优化特征，以及调整算法参数达到最佳预测性能。深度学习的方法通常不需要手动特征提取，它们能够直接从化合物的分子结构中自动学习到表示化合物性质的深层特征。利用深度神经网络，如多层感知器（MLP）、图神经网络（GNN）、门控循环单元（GRU）和 Transformer 等，这些方法能够处理复杂的分子结构信息，包括原子之间的连接关系和分子形状。深度学习模型通过在大量血-脑屏障渗透数据上的训练，能够捕捉更为细致和深层次的分子特性与血-脑屏障渗透性之间的关联，从而提供更为准确的预测。

扫描全能王
3亿人都在用的扫描App

## 四、药物毒性预测概览

药物毒性是指一种化合物对生物体造成的损害程度，包括急性毒性、特定器官毒性（图 2－41）、“三致”毒性等。

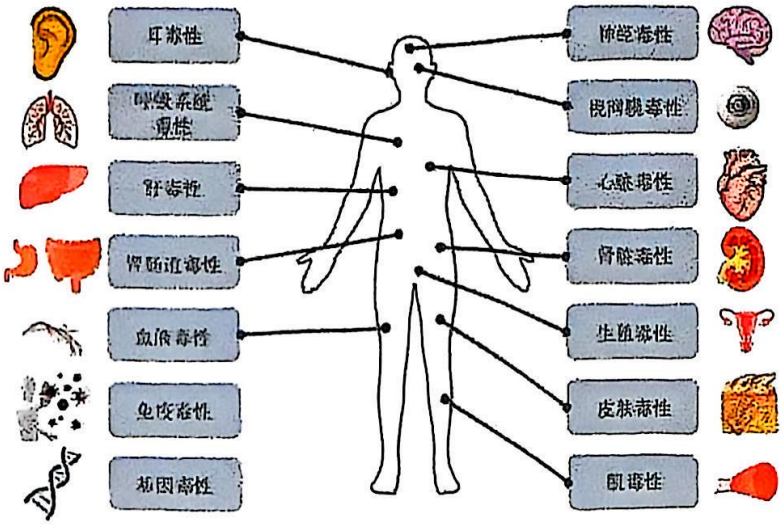


图 2－41　对人体某些器官的特定毒性

| Toxicity | | | |
|---|---|---|---|
| hERG Blockers | --- | ● | ● |
| 5-HT | + | ● | ● |
| DILI | +++ | ● | ● |
| AMES Toxicity | - | ● | ● |
| Rat Oral Acute Toxicity | -- | ● | ● |
| FDAMDD | ++ | ● | ● |
| Skin Sensitization | +++ | ● | ● |
| Carcinogenicity | + | ● | ● |
| Eye Corrosion | -- | ● | ● |
| Eye Irritation | + | ● | ● |
| Respiratory Toxicity | +++ | ● | ● |
| Environmental Toxicity | | | |
| Bioconcentration Factors | 0.087 | | ● |
| $IGC_{50}$ | 4.042 | | ● |
| $LC_{50}FM$ | 4.570 | | ● |
| $LC_{50}DM$ | 6.211 | | ● |
| Tox21 Pathway | | | |
| NR-AR | --- | ● | ● |
| NR-AR-LBD | + | ● | ● |
| NR-AhR | + | ● | ● |
| NR-Aromatase | - | ● | ● |
| NR-ER | - | ● | ● |
| NR-ER-LBD | - | ● | ● |
| NR-PPAR-gamma | +++ | ● | ● |
| SR-ARE | ++ | ● | ● |
| SR-ATAD5 | — | ● | ● |
| SR-HSE | — | ● | ● |
| SR-MMP | ++ | ● | ● |
| SR-p53 | ++ | ● | ● |

图 2－42　使用 ADMETlab 2.0 对 SMILES 式“CC(C)OC(=O)CC(=O)CSC1=C(C=C2CCCC2=N1)C#N”进行毒性预测的结果

通过计算建模技术，特别是定量构效关系这一框架，研究人员能够基于化合物的化学结构预测其毒性。这一过程涉及使用分子描述符或分子指纹来表征化合物，并采用了众多机器学习算法，如逻辑回归、随机森林和支持向量机等，以提高毒性风险评估的精确度。尽管如此，传统机器学习方法面临着“活性悬崖”和过拟合等挑战，这限制了其效能。相比之下，深度学习方法直接从化合物的分子结构（如 SMILES 字符串或分子图）学习预测毒性，无须手工提取特征，能够自动捕捉复杂的分子特征与毒性之间的关系，具有更多的优势。例如，ADMETlab 2.0（https://admetmesh.scbdd.com/），使用多任务图注意力框架进行模型训练，是一个集成了多种毒性预测模型的在线平台，能够提供包括呼吸系统毒性、心脏毒性等在内的 27 种毒性终点的预测服务（图 2－42）。

### （一）心脏毒性预测

在心肌细胞中，*hERG* 基因编码一种同源的四聚体钾离子通道蛋白。目前认为药物主要通过直接抑制 hERG 通道或阻碍 hERG 通道蛋白的转运产生心脏毒性。药物的临床前研究阶段显示，24%的药物因心血管系统的毒性反应而停止开发，而 45%的药物因引发心脏毒性反应被市场撤回。药物诱发的心脏毒性主要通过阻断快速激活延迟整流钾电流（IKr）引起，这导致心动作电位的 QT 间期（the interval between the start of the Q wave and the end of the T wave）延长，可能诱发尖端扭转型室性心动过速

扫描全能王
3亿人都在用的扫描App

(TdP),在严重情况下可能导致突然死亡。近年来,因心脏突发死亡事件,降低化合物对 hERG 钾通道的抑制作用是减少药物研发成本和提高成功率的关键。

近年来,基于 AI 的方法越来越多地被用于预测 hERG 的毒性。如基于 ML 的 RF、SVM、朴素贝叶斯(NBM)、KNN、极端梯度提升(XGBoost)和基于 DL 的 DNN、ANN、RNN、CNN、GNN、GCNN、GAT 等,被广泛用于 hERG 预测(表 2-4)。

表 2-4　一些现有报道的二分类 hERG 预测模型

| 方　法 | 特　征 | 数据集大小 | 参 考 文 献 |
|---|---|---|---|
| RF | 2D 描述符 | 8 382 | arXiv, 2021, 2112, 13467 |
| SVM | ECFP_4 FP, 2D/3D 描述符 | 291 000 | Sci. Rep, 2019, 9, 12220 |
| MT-DNN | MACCS FP | 7 889 | J. Chem. Inf. Model, 2019, 59, 1073-1084 |
| DMPNN | 9 种 FP | 14 409 | RSC Adv, 2022, 12, 3423 |
| RF, NBM, SVM, ANN, Bagging | FCFP_2, FCFP_4, FCFP_6 FP | 5 299 | Molecules, 2020, 25, 2615 |
| MGAF | 分子图 | 13 845 | Nucleic Acid Res, 2021, 49, W5-W14 |
| 自注意力机制 | ECFP_6 FP | 10 453 | Comput. Biol. Chem, 2020, 87, 107286 |

FP 为 FingerPrints,分子指纹;ACC 为 accuracy,准确度;ROC-AUC 为 the area under the receiver operating characteristic curve,受试者工作特征曲线下面积;MCC 为 Matthew's correlation coefficient,马修相关系数。

相比于基于单任务学习框架的模型,基于多任务深度学习(MT-DNN)的 deephERG,通过融合分子操作环境(MOE)描述符和 Mol2Vec 描述符来表征化合物,使用 hERG 通道的最大半抑制浓度($IC_{50}$)作为标签,以此来划分用于多任务学习的子任务数据集。在训练数据集和验证数据集上,该模型展现了卓越的性能,ROC-AUC 值分别达到了 0.944 和 0.967。此外,也有学者提出了用于预测 hERG 抑制剂的可解释深度学习模型——hERG-Att,该模型基于自注意力机制,通过更新特征重要性权重矩阵来训练模型,因此具有较强的可解释性。

**知识拓展:可解释性**

*可解释性目前没有一个确切的定义,可以简单理解为可解释性是人类可以理解决策原因的程度。对于模型给出的预测,人们往往倾向于认同可完全理解的决策过程,以及根据模型给出的决策理由来判断是否接受该预测结果。*

(二)"三致"毒性预测

"三致"毒性包括 3 类:致畸性、致癌性和致突变性。

为了预测致畸毒性,研究者们常采用以下几种特征来构建模型:化学描述符,用以表征化合物中的化学基团及其相互作用;包括药物相似性、分子能学和突变性在内的元结构特征。此外,还包括一些与致畸毒性直接相关的特定靶标。致畸毒性的分类规则通常基于美国 FDA 的致畸性评分标准(表 2-5)。Challa 等使用无监督学习方法(t-SNE)和有监督学习方法(梯度提升机)分析药物分子,考察了包括结构、元结构和体外生物活性数据在内的广泛药物信息,以识别与致畸性评分相关的模式。他们发现了 3 种可能增加药物致畸性的化学官能团,以及两种可能具有保护作用的分子。研究中,他们采用了一个重新定义的致畸性评分系统,将致畸性风险分为临床可接受风险(包括原 FDA 评分中的 A/B 评级)、中等风险(C 评级的药物)和临床不可接受风险(D/X 评级的药物)。该模型在预测 3 种临床相关致畸

扫描全能王
3亿人都在用的扫描App

性风险的能力上，其 AUC 值达到了 0.8，预测准确率几乎是同一任务在一个没有使用任何特定特征或知识进行训练的模型中的两倍。

表 2-5 致畸毒性的分类规则

| 分 类 | 属 性 |
|---|---|
| A | 一般可接受。在孕妇中进行的对照研究没有证据表明有胎儿风险 |
| B | 可能可接受。要么动物研究表明没有风险，但尚未进行人体研究，要么动物研究表明有较小的风险，而人类研究表明没有风险 |
| C | 如果治疗效果大于风险，需谨慎使用。动物研究表明有风险但没有人体研究，或者既没有动物研究也没有人体研究 |
| D | 仅在危及生命的紧急情况下，没有更安全的药物可用时使用。有明确证据表明具有人体致畸风险 |
| X | 妊娠期请勿使用。具有人体致畸风险，并且存在更安全的替代品 |
| N/A | 没有有效信息 |

致癌性和致突变毒性预测方法都可分为专家系统、定性构效关系模型和定量构效关系模型。

专家系统依赖于一系列精确的规则来分析和推断化学物质的致癌机制，其预测准确率可达 70%。在这一类方法中，树模型是常用的技术，它通过“剪枝技术”来进行预测。专家系统的优势在于其能够模拟人类专家的判断过程，提供明确的逻辑路径和解释能力。

定性和定量的构效关系模型旨在建立分子特征与化学物质致癌性（及致突变性）之间的关联。这些模型使用的方法包括朴素贝叶斯、XGBoost、SVM 和 KNN 等算法。这类模型通过分析化学结构与生物活性之间的关系，为预测提供了数学上的精确度。

随着深度学习技术的进步，更先进的方法如卷积神经网络（CNN）和人工神经网络（ANN）也被应用于致癌性和致突变毒性的预测中。Wang 等开发了一个基于动态路由算法的深度学习方法 CapsCarcino，用于区分致癌物和非致癌物，这种方法能够在需要较少数据的同时，提取更全面的信息，并且避免了特征选择的步骤。Li 等使用了一种图卷积神经网络结构来识别分子特征，并基于这些特征开发预测模型，其模型不仅可以预测化合物的致突变性，还可以识别化合物中的警示结构。

## 五、半衰期

在药代动力学中，药物在体内的代谢过程按一级动力学过程进行，所以药物在体内存在相对稳定的半衰期，称为药物消除半衰期（$t_{1/2}$），其定义是药物在生物体内浓度下降一半所需要的时间。$t_{1/2}$ 由血浆清除率（CL）和分布容积（$V_d$）决定，其公式如式 2-9 所示。

$$t_{1/2} = \frac{\ln 2 \cdot V_d}{CL} \qquad \text{（式 2-9）}$$

药物在体内代谢的 $t_{1/2}$ 受到较多因素的影响，不同的药物具有不同的 $t_{1/2}$，甚至一些药理作用相同结构相似的药物其 $t_{1/2}$ 也存在显著差异。例如，红霉素及其类似物阿奇霉素（图 2-43）的 $t_{1/2}$ 分别为 0.8~3 h 和 35~41 h。

测量给定药物的 $t_{1/2}$ 对于药物的安全和准确剂量非常重要。但是，$t_{1/2}$ 的实验评估既耗时又昂贵因此，建立准确的 $t_{1/2}$ 预测模型受到科研人员的关注。Turner 等通过整合结构、拓扑和量子化学描述符开发了一种人工神经网络模型，预测了 20 种头孢菌素的人体 $t_{1/2}$、CL、$V_d$ 等。Arnot 等使用来自同行评

扫描全能王
3亿人都在用的扫描App

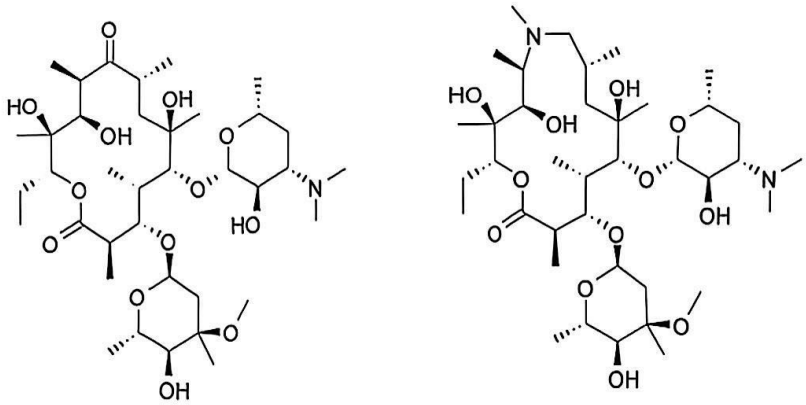

图 2－43　红霉素(左)和阿奇霉素(右)的结构

两种化合物的结构差异用蓝色标出

审文献和公共资源的人类总消除 $t_{1/2}$ 数据，采用分子片段和自动迭代片段选择方法开发了多元线性回归模型。Sharma 等基于 10 mer (HL10)和 16 mer (HL16)的肽数据集，提出了一种预测模型，用于评估肽在类肠环境中的 $t_{1/2}$，这个模型可以用来相对地而非绝对地估计肽的 $t_{1/2}$。王永华等提出了适用于中药注射系统的预测 $t_{1/2}$ 模型，这是一个通过偏最小二乘预测药物 $t_{1/2}$ 长短的系统决策模型。

郑明月等借助 7 种机器学习方法和分子描述符，建立了准确的 $t_{1/2}$ 预测模型。这项研究采用了多种机器学习方法，包括梯度提升机、径向基核函数支持向量回归(RBF－SVR)、局部惰性回归(LLR)等，来构建高质量预测模型。其中，GBM 表现出最好的性能(测试集的 $R=0.820$ 和 RMSE＝0.555)，优于 Arnot 等的模型性能(测试集的 $R=0.723$ 和 RMSE＝0.698)。此类预测 $t_{1/2}$ 的模型将在早期药代动力学评估中具有潜在的应用，并为设计具有良好体内暴露曲线的候选药物提供指导。

## 第五节　人工智能赋能临床监测与诊断

随着 AI 在医药领域的应用迅猛增长，其在临床监测和医学诊断领域也取得了显著进展。AI 可以增强诊断精准度和效率、实施实时健康监控和风险评估及提供个性化治疗建议，极大地优化了医疗诊断流程，对于提升医疗服务效率、优化资源配置，以及改善患者体验具有重要意义。

### 一、人工智能增强诊断准确度和效率

多领域的研究结果均指出，搭载 AI 的医学影像系统目前在准确性与速度方面已表现得十分出色。计算机视觉和深度学习技术的结合使得 AI 能够快速、准确地分析医学影像，如 X 射线(X-ray)、计算机断层扫描(CT)和磁共振成像(MRI)。因此，AI 系统可以帮助医生检测肿瘤、骨折或其他病变，提供更早期的诊断和治疗。有研究团队将大型的乳房 X 射线照片数据集输入 AI 系统训练乳腺癌诊断模型，发现与专家相比，AI 诊断乳腺癌的假阳性和假阴性分别减少了 5.7%和 9.4%(绝对比例)。另一项针对 625 个病例进行急性阑尾炎诊断的研究，利用多种机器学习模型，发现使用随机森林算法性能最佳，可以准确预测 83.75%的病例。

通过 AI 辅助诊断，不仅能够提高诊断的准确性与效率，还可以通过分析患者的数据，根据协助对患者根据病情的紧迫性进行分类，从而可以优先考虑高危病例，减少等待时间，优化资源配置。

扫描全能王
3亿人都在用的扫描App